



МІНІСТЕРСТВО ОСВІТИ І НАУКИ, МОЛОДІ ТА СПОРТУ УКРАЇНИ

НАЦІОНАЛЬНИЙ ТЕХНІЧНИЙ УНІВЕРСИТЕТ УКРАЇНИ

«КИЇВСЬКИЙ ПОЛІТЕХНІЧНИЙ ІНСТИТУТ»

ФІЗИКО-ТЕХНІЧНИЙ ІНСТИТУТ

Комп'ютерний практикум №1

з дисципліни КRYPTOґРАФІЯ:

«Експериментальна оцінка ентропії на символ джерела відкритого тексту»

Виконали:

Студенти групи ФБ-96

Шафрай Ілля

Шидлюх Максим

Київ 2021

### **Мета роботи**

Засвоєння понять ентропії на символ джерела та його надлишковості, вивчення та порівняння різних моделей джерела відкритого тексту для наближеного визначення ентропії, набуття практичних навичок щодо оцінки ентропії на символ джерела.

## Завдання

1. Написати програми для підрахунку частот букв і частот біграм в тексті, а також підрахунку  $H_1$  та  $H_2$  за безпосереднім означенням. Підрахувати частоти букв та біграм, а також значення  $H_1$  та  $H_2$  на довільно обраному тексті російською мовою достатньої довжини (щонайменше 1Мб), де імовірності замінити відповідними частотами. Також одержати значення  $H_1$  та  $H_2$  на тому ж тексті, в якому вилучено всі пробіли.
2. За допомогою програми CoolPinkProgram оцінити значення (10)  $H$  , (20)  $H$  , (30)  $H$  .
3. Використовуючи отримані значення ентропії, оцінити надлишковість російської мови в різних моделях джерела.

## Хід роботи

### Завдання 1

В цій частині було визначено частоти простих і перехресних біграм. За цими показниками була визначена ентропія для біграм і літер. Частота біграм отсортована по їх буквенним значенням а для літер за зростанням частоти

Частота літер

З пробілами	Без пробілів
0.1510455365672434," ",	0.08214553638409602,"е",
0.06973781976435622,"е",	0.0792698174543636,"о",
0.06729646534338181,"о",	0.07676919229807452,"а",
0.06517354845557796,"а",	0.07401850462615654,"и",
0.06283833987899373,"и",	0.060515128782195546,"в",
0.051374588684852986,"в",	0.05951487871967992,"т",
0.05052542192973145,"т",	0.04913728432108027,"н",
0.041715316845345504,"н",	0.047636909227306824,"к",
0.0404415667126632,"к",	0.045636409102275566,"л",
0.038743233202420124,"л",	0.0450112528132033,"р",
0.038212503980469166,"р",	0.03363340835208802,"с",
0.02855323214096168,"с",	0.029882470617654415,"у",
0.025368856809255918,"у",	0.029132283070767692,"ы",
0.024731981742914765,"ы",	0.029007251812953237,"п",
0.024625835898524573,"п",	0.022630657664416104,"м",
0.022078335633159963,"я",	0.018629657414353587,"х",
0.019212397834624775,"м",	0.018629657414353587,"ш",
0.015815730814138628,"х",	0.01800450112528132,"ц",

0.015815730814138628,"ш",	0.016129032258064516,"д",
0.015285001592187666,"ц",	0.015753938484621154,"з",
0.013692813926334785,"д",	0.013378344586146536,"г",
0.013374376393164208,"з",	0.013378344586146536,"ж",
0.011357605349750556,"г",	0.012503125781445362,"й",
0.011357605349750556,"ж",	0.012128032008002,"б",
0.010614584439019213,"й",	0.012003000750187547,"ю",
0.010296146905848636,"б",	0.01037759439859965,"ч",
0.010190001061458443,"ю",	0.009252313078269568,"ь",
0.008810105084385947,"ч",	0.006876719179794949,"щ",
0.007854792484874216,"ь",	0.005751437859464866,"ф",
0.0058380214414605665,"щ",	0.002625656414103526,"э",
0.004882708841948837,"ф",	
0.0022290627321940345,"э",	

Частота біграм (20 найчастіших)

З пробілами	Без пробілів
0.02635658914728682,"и ",	0.015249112659392664,"на",
0.021705426356589147,"т ",	0.013671618246352045,"ка",
0.0212624584717608,"а ",	0.01327724464309189,"он",
0.016611295681063124," в",	0.011831208097804654,"ер",
0.014285714285714285," п",	0.011831208097804654,"ов",
0.013953488372093023,"е ",	0.01091100302353096,"ки",
0.012846068660022148,"на",	0.01091100302353096,"ре",
0.012070874861572536," н",	0.010253713684764033,"ва",
0.011738648947951274,"о ",	0.009596424345997109,"ло",
0.011517165005537098,"ка",	0.009333508610490338,"ив",
0.011406423034330012,"в ",	0.009333508610490338,"ст",
0.010188261351052049," к",	0.009333508610490338,"во",
0.009966777408637873,"ер",	0.008544761403970027,"ры",
0.00919158361018826,"ре",	0.008544761403970027,"ев",
0.009080841638981174," л",	0.008413303536216643,"ни",
0.008859357696566999,"он",	0.008413303536216643,"ле",

0.008637873754152824," о",	0.008413303536216643,"ах",
0.008527131782945736," и",	0.008150387800709872,"ол",
0.008416389811738648,"ки",	0.008150387800709872,"ес",
0.008084163898117386,"ло",	0.008018929932956487,"ет",
0.007862679955703212,"ст",	0.0077560141974497175,"ит",

Ентропія для букв без пробілів: 4.353148523001946

Надлишковість: 0.8548950492332685

Ентропія для букв з пробілами: 4.419377566114722

Redundancy 0.8618944510589149

Ентропія для біграм без пробілів: 4.038541077351004

Надлишковість: 0.8653819640882998

Ентропія біграм з пробілами: 3.9104802888234858

Надлишковість: 0.8777974909742661

Завдання 2

Лабораторная работа №1

✕

Произвольная часть текста:

лучением\_

Использованные буквы:

Порядок n-граммы:

5 символов

10 символов

15 символов

20 символов

25 символов

30 символов

35 символов

40 символов

45 символов

50 символов

Введенный символ:

Символ по счету:

Номер эксперимента:

50

Неравенство для энтропии:

$3,31379269302549 < H < 3,85098771375663$

Двоичная таблица угаданных символов:

00000001000000000000000000000000

00000000100000000000000000000000

00000000000000000000000000000001

00000000000000000000000000000000

00000000000000000000000000000001

Поле ввода символов:

Продолжить

Другой

Вероятности:

$q[1] = 0,2857142$

$q[2] = 0,1020408$

$q[3] = 0,0408163$

$q[4] = 0,0204081$

$q[5] = 0,0408163$

$q[6] = 0,0204081$

$q[7] = 0,0204081$

$q[8] = 0,0204081$

$q[9] = 0,0612244$

$q[10] = 0$

$q[11] = 0,020408$

$q[12] = 0$

$q[13] = 0,020408$

$q[14] = 0$

$q[15] = 0,020408$

$q[16] = 0,040816$

$q[17] = 0,020408$

$q[18] = 0,040816$

$q[19] = 0,020408$

$q[20] = 0,040816$

$q[21] = 0$

$q[22] = 0$

$q[23] = 0$

$q[24] = 0$

$q[25] = 0$

$q[26] = 0,020408$

$q[27] = 0$

$q[28] = 0,020408$

$q[29] = 0$

$q[30] = 0,020408$

$q[31] = 0,040816$

$q[32] = 0,061224$

Строка состояния:

Лабораторная работа №1

✕

Произвольная часть текста:

о\_когда\_мыслители\_д

Использованные буквы:

Порядок n-граммы:

5 символов

10 символов

15 символов

20 символов

25 символов

30 символов

35 символов

40 символов

45 символов

50 символов

Введенный символ:

Символ по счету:

Номер эксперимента:

51

Неравенство для энтропии:

$2,10330345874846 < H < 2,66111918856318$

Двоичная таблица угаданных символов:

01000000000000000000000000000000

10000000000000000000000000000000

10000000000000000000000000000000

10000000000000000000000000000000

00001000000000000000000000000000

Поле ввода символов:

Продолжить

Другой

Вероятности:

$q[1] = 0,54$

$q[2] = 0,06$

$q[3] = 0,08$

$q[4] = 0$

$q[5] = 0,02$

$q[6] = 0$

$q[7] = 0$

$q[8] = 0,02$

$q[9] = 0$

$q[10] = 0$

$q[11] = 0$

$q[12] = 0$

$q[13] = 0$

$q[14] = 0,04$

$q[15] = 0,02$

$q[16] = 0,02$

$q[17] = 0,04$

$q[18] = 0$

$q[19] = 0$

$q[20] = 0$

$q[21] = 0,04$

$q[22] = 0,02$

$q[23] = 0,02$

$q[24] = 0,02$

$q[25] = 0$

$q[26] = 0$

$q[27] = 0,02$

$q[28] = 0$

$q[29] = 0,04$

$q[30] = 0$

$q[31] = 0$

$q[32] = 0$

Строка состояния:

Произвольная часть текста:  
кон\_порядочного\_поведения\_зна

Использованные буквы:

Порядок n-граммы:  

5 символов  
10 символов  
15 символов  
20 символов  
25 символов  
30 символов  
35 символов  
40 символов  
45 символов  
50 символов

Введенный символ:

Символ по счету:

Номер эксперимента: 51

Поле ввода символов:  

Продолжить Другой

Неравенство для энтропии:  
1,9528741426435< H < 2,68402412911771

Двоичная таблица угаданных символов:  

01000000000000000000000000000000 ^  
10000000000000000000000000000000 |  
0000000000000000000000000100000000 v  
01000000000000000000000000000000  
10000000000000000000000000000000  
ooooooooooooooo

Вероятности:  

q[1]=0,54  
q[2]=0,1  
q[3]=0,04  
q[4]=0,02  
q[5]=0,02  
q[6]=0  
q[7]=0,02  
q[8]=0,02  
q[9]=0  
q[10]=0  
q[11]=0,04  
q[12]=0  
q[13]=0  
q[14]=0  
q[15]=0,04  
q[16]=0,02  
q[17]=0,02  
q[18]=0  
q[19]=0  
q[20]=0,04  
q[21]=0,02  
q[22]=0  
q[23]=0  
q[24]=0,02  
q[25]=0,02  
q[26]=0  
q[27]=0  
q[28]=0  
q[29]=0  
q[30]=0,02  
q[31]=0  
q[32]=0

Строка состояния:

Отримали значення:

$$3.31379 < H(10) < 3.85098$$

$$2.10330 < H(20) < 2.66119$$

$$1.95287 < H(30) < 2.68402$$

### Значення надлишковості

$$0.33724 > R(10) > 0.22980$$

$$0.57934 > R(20) > 0.46776$$

$$0.60942 > R(30) > 0.46319$$

### Висновок:

Засвоїли поняття ентропії на символ джерела та його надлишковості, порівняння різних моделей джерела відкритого тексту для наближеного визначення ентропії, набуття практичних навичок щодо оцінки ентропії на символ джерела.